



Programa Certified AI-LLM Solution Architect

Fundamentos de Arquitectura LLM

Sesión 5 · Evaluación, Costeo y Ética en el Uso de LLM

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 25 años de experiencia
- PGP Artificial Intelligence & Machine Learning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data – IEBSchool
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialista en MLOps de la Universidad de Duke
- Estudiante de Deep Learning for Healthcare Specialization
- Director de Inteligencia Artificial e Innovacion Universidad EAN/Colombia



anrojas@universidadean.edu.co / arojaspa@outlook.com / arojaspa76



@arojaspa



<https://www.linkedin.com/in/arojaspa/>



+573005906373



Evaluación, Costeo y Ética en el Uso de LLM

Evaluación ligera, LLM-como-juez, costeo por llamada y a escala, y gobernanza ética bajo NIST y el EU AI Act

Ubicación en el Curso

Las sesiones anteriores del Capítulo 2 dejaron un PoC funcional: llamadas API bien construidas, seguridad básica bajo OWASP, prompting con respaldo en investigación y agentes con patrón ReAct.

Esta sesión cierra el Capítulo 2 aplicando disciplina de medición — calidad, seguridad, costo y ética — sobre esos PoCs, antes de decidir si un PoC avanza a la siguiente etapa.

PROGRESO DEL CURSO · 10 SESIONES

1

2

3

4

5

6

7

8

9

10

Agenda — Sesión 5

Tres bloques de trabajo · Cierre del Capítulo 2 con disciplina de medición

01

70 min

Calidad y Seguridad en un PoC

- ▶ Los tres riesgos de un PoC sin evaluación formal
- ▶ Cuatro dimensiones: corrección, fidelidad, seguridad, costo-latencia
- ▶ Faithfulness: la métrica que más se ignora (RAGAS)
- ▶ Conexión con OWASP: la seguridad ya vista en la Sesión 4

02

70 min

Evaluación Ligera y Dataset Dorado

- ▶ De HELM a un harness de PoC: 2-3 métricas ligeras y deterministas
- ▶ Cómo construir un dataset dorado mínimo (10-30 ítems)
- ▶ LLM-como-juez (G-Eval): poder y sesgos documentados
- ▶ Métricas ligeras exactas del harness: léxico, cautela, longitud

03

40 min

Costeo, Ética y Registro

- ▶ De tokens a decisión de negocio: costo por llamada y proyectado
- ▶ Gobernanza ética: NIST AI RMF y el Reglamento de IA de la UE
- ▶ Demo guiada: el PoC de Tienda Andina, de dataset a registro
- ▶ Síntesis: un marco integral de evaluación, costeo y ética

Los Tres Riesgos de un PoC sin Evaluación Formal

Tema 1 · Qué puede salir mal cuando nadie mide un PoC antes de avanzar

01 Alucinación Silenciosa

El modelo responde con total confianza formal aunque esté inventando: no hay una señal visible de incertidumbre. Sin un dataset de referencia que lo detecte, un PoC puede parecer sólido y no serlo.

"Suenaseguro. Puede estar mal."

Lin, Hilton & Evans, 2022 — "TruthfulQA: Measuring How Models Mimic Human Falsehoods", arXiv:2109.07958

02 Sobre-Costo No Proyectado

Un PoC que "funciona" en la demo puede ser inviable a escala si nadie calculó el costo real por llamada ni lo proyectó al volumen esperado de usuarios.

"Funciona en la demo. ¿A qué costo?"

→ Tema 3 de esta sesión: costo por llamada y proyección de negocio

03 Riesgo Ético/Legal Sin Documentar

Sin un checklist ético explícito, decisiones de riesgo (transparencia, alcance, verificación humana) quedan implícitas — y ya vimos en la Sesión 4 que eso tiene consecuencia legal real.

"Ya lo vimos: Mata v. Avianca."

→ Casos ya vistos en la Sesión 4: Mata v. Avianca y Moffatt v. Air Canada

Qué Medir en un PoC: Cuatro Dimensiones

Tema 1 · Cuatro preguntas antes de confiar en un modelo, sin excepción

Dimensión	Pregunta que responde
Corrección	¿La respuesta es factualmente correcta para el dominio de negocio?
Fidelidad / Alucinación	¿La respuesta está sustentada por el contexto o la referencia, o inventa?
Seguridad	¿Resiste prompt injection y respeta su alcance? (conecta con OWASP, Sesión 4)
Costo-Latencia	¿Cuánto cuesta y qué tan rápido es, proyectado a escala de producción?

Las cuatro dimensiones se responden con herramientas distintas: dataset dorado, RAGAS/faithfulness, OWASP, y la fórmula de costeo de esta sesión.

 Regla práctica: un PoC no avanza si no puede responder las cuatro preguntas con evidencia, no con intuición.

Faithfulness: la Métrica Más Importante que se Ignora

Tema 1 · Distinta de "corrección" — y la que casi nadie mide en un PoC

El Concepto

Faithfulness ("fidelidad") mide si la respuesta está sustentada por el contexto o la referencia entregada al modelo — o si inventa información que ese contexto no soporta. No es lo mismo que "corrección": una respuesta puede ser correcta por accidente y no fiel, o fiel a un contexto que en sí mismo está equivocado.

El Framework: RAGAS

RAGAS formaliza la fidelidad con inferencia de lenguaje natural (NLI): descompone la respuesta en afirmaciones y verifica cuáles están sustentadas por el contexto recuperado — un método reproducible, no una impresión subjetiva.

Es, James, Espinosa-Anke & Schockaert, 2023 — "Ragas: Automated Evaluation of Retrieval Augmented Generation", EACL 2024, arXiv:2309.15217

 Un modelo puede ser fluido y seguro y aun así no ser fiel — por eso faithfulness va en el harness, no solo en la revisión manual.

De HELM a un Harness de PoC

Tema 2 · El estándar de la industria — y por qué es prematuro para un solo PoC

01 Precisión (Accuracy)	02 Calibración (Calibration)	03 Robustez (Robustness)	04 Equidad (Fairness)	05 Eficiencia (Efficiency)
06 Toxicidad (Toxicity)	07 Sesgo (Bias)	08 Razonamiento (Reasoning)	09 Resumen (Summarization)	10 Conocimiento (Knowledge)

Por qué esto es prematuro para un solo caso de uso

HELM	→ Evalúa decenas de dimensiones (arriba) para comparar modelos base a escala de industria — el estándar correcto para esa pregunta (Liang et al., 2022, arXiv:2211.09110, Stanford CRFM).
PoC	→ Un PoC de un solo caso de uso no necesita las diez dimensiones: necesita responder si ESTE modelo funciona para ESTA tarea.
Harness	→ Por eso el harness de esta sesión usa solo 2-3 métricas ligeras y deterministas — ver la siguiente diapositiva.

Las 3 Métricas Ligeras del Harness de la Sesión

Tema 2 · Deterministas, baratas y suficientes para decidir si un PoC avanza

01 Superposición Léxica

Compara los tokens clave de la respuesta del modelo contra la respuesta de referencia del dataset dorado. Simple, determinista y barata — el primer filtro antes de gastar en evaluación más costosa.

$$\text{score} = \text{tokens_comunes} / \text{tokens_referencia}$$

Implementada en `evaluacion.py` — métrica propia del harness de esta sesión.

02 Cautela Apropiaada

En preguntas de alto riesgo de alucinación, evalúa si el modelo reconoce sus límites en vez de inventar con exceso de confianza — penaliza la sobreconfianza, no la incertidumbre honesta.

"No cuento con ese dato en el catálogo."

Implementada en `evaluacion.py` — dirigida a las preguntas de riesgo alto del dataset dorado.

03 Longitud Relativa

Compara la longitud de la respuesta contra la longitud esperada de la referencia. Sospechosamente corta puede indicar evasión; sospechosamente larga, relleno o alucinación elaborada.

$$\text{longitud_respuesta} / \text{longitud_referencia} \approx 1$$

Implementada en `evaluacion.py` — señal ligera, nunca decisiva por sí sola.

Cómo Construir un Dataset Dorado Mínimo

Tema 2 · Cuatro criterios antes de correr el harness por primera vez

1 · 10–30 Ítems	Suficiente para un PoC — no hace falta un benchmark de miles de ítems para decidir si un caso de uso funciona.	<i>vs. cientos en un benchmark académico</i>
2 · Referencia Validada por Humano	Cada ítem necesita una respuesta de referencia validada por una persona — nunca generada por el mismo LLM que se va a evaluar.	<i>no LLM-generado</i>
3 · Categorías de Riesgo Variadas	Debe cubrir preguntas triviales, preguntas donde inventar es peligroso, preguntas fuera de alcance, e intentos de inyección de prompt o manipulación.	
4 · Versionado como Código	El dataset cambia con el producto — debe versionarse igual que cualquier otro artefacto de código, no vivir suelto en un documento aparte.	

LLM-Como-Juez: Poder y Sesgos Documentados

G-Eval (Liu et al., 2023) · MT-Bench / Chatbot Arena (Zheng et al., 2023)

El Método: G-Eval

Un LLM (GPT-4) puntúa la calidad de otra respuesta siguiendo una cadena de razonamiento explícita definida por el evaluador, en vez de una regla léxica fija.

Correlaciona mejor con el juicio humano que las métricas léxicas clásicas (BLEU, ROUGE) — Liu et al., 2023, EMNLP 2023, arXiv:2303.16634.

Los Sesgos Documentados

Zheng et al. (2023) documentan tres sesgos sistemáticos en LLM-como-juez: sesgo de posición, sesgo de verbosidad (prefiere respuestas más largas aunque no sean mejores) y sesgo de auto-preferencia (el juez favorece salidas de modelos de su misma familia).

Zheng, L. et al., 2023 — "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena", NeurIPS 2023, arXiv:2306.05685.



Por eso en el harness de esta sesión el LLM-como-juez es SIEMPRE opcional y nunca la única señal.

Registro de Resultados: de la Corrida a la Comparativa

Tema 3 · Sin registro, cada corrida se olvida y no hay comparación posible

Qué se Registra

Cada corrida del harness debe quedar registrada con: proveedor, modelo, dataset dorado usado, score obtenido, costo, latencia, y quién aprobó la corrida — nunca solo el número final.

Por Qué Importa

Permite comparar proveedores y modelos de forma objetiva — no por impresión — y da trazabilidad post-hoc: si algo falla en producción, se puede reconstruir qué corrida aprobó ese modelo y con qué evidencia.

Implementado en `registro.py` — el registro es un artefacto, no una nota informal.



Un score sin registro es una anécdota — con registro, es evidencia que sostiene la decisión de avanzar el PoC.

Costeo: de Tokens a Decisión de Negocio

Tema 3 · Dos preguntas distintas, dos fórmulas distintas — no se confunden

1 Costo de una Llamada

Cuánto cuesta UNA respuesta del modelo. Se calcula a partir de los tokens de entrada y de salida, cada uno con su propia tarifa por millón de tokens (input y output casi siempre difieren).

$$\text{costo} = (\text{in}/1\text{M} \times \text{tarifa_in}) + (\text{out}/1\text{M} \times \text{tarifa_out})$$

→ costo unitario, la base de todo lo demás

2 Proyección del PoC

Cuánto va a costar el PoC a escala de negocio. Requiere estimar cuántos usuarios lo usarán y cuántas llamadas hace cada uno al mes — una pregunta de producto, no de ingeniería.

$$\text{proy.} = \text{usuarios} \times \text{llamadas/usuario/mes} \times \text{costo_prom}$$


→ la cifra que de verdad le importa al negocio

⚠ Son dos preguntas distintas y se confunden con frecuencia: el costo por llamada explica la demo; la proyección explica si el negocio se sostiene.

🔑 Implementado en `costeo.py` — ambas fórmulas deben quedar en el registro de resultados de cada corrida.

Gobernanza Ética: el Marco NIST AI RMF

Tema 3 · Un ciclo continuo, no una casilla que se marca una sola vez



Las cuatro funciones — Gobernar, Mapear, Medir, Gestionar — se repiten de forma continua, no una sola vez al lanzar el PoC.

National Institute of Standards and Technology (NIST), 2023 — "AI Risk Management Framework (AI RMF 1.0)"



El checklist ético de la siguiente diapositiva se apoya directamente en Medir y Gestionar — la evaluación y el costeo alimentan la decisión de gestión.

El Reglamento de IA de la UE: Niveles de Riesgo

Tema 3 · Reglamento (UE) 2024/1689 — en vigor desde agosto de 2024


Nivel de Riesgo	Estatus	Ejemplo	Auditoría	Obligación Clave
Inaceptable	Prohibido	Manipulación subliminal, scoring social	N/A	Prohibido por completo en la UE — sin excepción de mitigación.
Alto	Permitido con requisitos	Selección de personal, crédito, salud	Obligatoria	Auditoría, documentación técnica y supervisión humana obligatorias.
Limitado	Permitido	Chatbots, asistentes conversacionales	No	Transparencia explícita: el usuario debe saber que habla con una IA.

Falta el nivel "Mínimo" en esta tabla (filtros de spam, videojuegos con IA, recomendadores simples): permitido sin obligaciones especiales bajo el Reglamento.

🔑 Un asistente de soporte al cliente típico cae en "Limitado" — lo que implica una obligación concreta: transparencia explícita, siempre.

De la Teoría a la Práctica: el PoC de Tienda Andina

Tema 3 · El mismo pipeline de evaluación, costeo y ética aplicado de punta a punta



Stack Técnico

Backend FastAPI (Python) — orquesta harness, costeo y checklist

Frontend React 18 + Vite 6 — dashboard de resultados

Modelo local Ollama — para correr el harness sin costo de API

Guía Paso a paso local — ver session_5/GUIA_OLLAMA.md

El Código Vive en el Repo — No en Esta Diapositiva

- ▶ El pipeline completo — dataset, harness, costeo, checklist y registro — está implementado y documentado en el repo de la sesión.
- ▶ El objetivo de la clase es entender el marco de decisión, no transcribir código — el repo se recorre en la práctica guiada.
- ▶ Todos los archivos citados en esta sesión (evaluacion.py, costeo.py, etica.py, registro.py) están en ese repo.

Síntesis: un Marco Integral

El checklist antes de decidir si un PoC avanza a producción

Qué Medir

- ✓ Cuatro dimensiones sin excepción: corrección, fidelidad/alucinación, seguridad y costo-latencia.
- ✓ Un PoC no avanza si no puede responder las cuatro con evidencia, no con intuición.

Cómo Medir Ligero

- ✓ Superposición léxica, cautela apropiada y longitud relativa sobre un dataset dorado de 10-30 ítems.

Costeo

- ✓ Costo por llamada (tokens $\times$ tarifa) y proyección de negocio (usuarios $\times$ uso $\times$ costo) — dos preguntas distintas.
- ✓ LLM-como-juez (G-Eval) es opcional y complementario — nunca la única señal, por sus sesgos documentados.

Ética

- ✓ Checklist bajo NIST AI RMF (Gobernar-Mapear-Medir-Gestionar) y el EU AI Act (nivel de riesgo y su obligación).



Resumen de la Sesión 5



Evaluación ligera no es evaluación sin rigor: 4 dimensiones, siempre.



LLM-como-juez es poderoso pero sesgado: posición, verbosidad, auto-preferencia.



La ética es un checklist con bloqueantes (NIST + EU AI Act), no una reflexión opcional.



Faithfulness es la métrica que más se ignora — y la que más importa (RAGAS).



El costo se calcula en dos niveles distintos: por llamada y proyectado a negocio.



Cierra el Capítulo 2: el PoC ya tiene evidencia para decidir si avanza.



Recursos del Curso

Dataset dorado → `dataset_dorado.json`

Harness de evaluación → `evaluacion.py`

Costeo → `costeo.py`

Checklist ético → `etica.py`

Registro y guía de pruebas local → `registro.py` · `GUIA_OLLAMA.md`